

基于图神经网络的芯片封装二维稳态热场代理模型

技术说明文档 (chip-thermal-gnn)

项目自动生成报告 (实验结果均为本机实测)

August 28, 2026

Contents

1	项目概述	2
1.1	核心任务定义	2
1.2	技术栈	2
1.3	项目目录结构	2
2	物理模型与假设	2
2.1	几何结构	2
2.2	控制方程	3
2.3	边界条件 (简化设置)	3
2.4	热源设置	4
2.5	明确的物理简化假设	4
3	数据生成与图构建	4
3.1	有限元离散	4
3.2	数据集划分	4
3.3	图数据表示	5
4	模型设计	5
4.1	主模型: MeshGraphNet 风格 Encode-Process-Decode	5
4.2	基线模型	5
4.3	损失函数与训练策略	5
5	评估指标与实验结果	6
5.1	整体对比	6
5.2	分布内 / 分布外分拆	7
5.3	峰值温度散点图	7
6	温度场可视化	8
7	复现实验步骤	10
8	局限性与后续扩展	11
8.1	当前局限性	11
8.2	从稳态扩展到瞬态	11
9	结论	11
A	主要输出文件索引	11

1 项目概述

本项目实现了一个可复现的 Python 研究演示系统 chip-thermal-gnn，目标是构建 **基于图神经网络（GNN）的芯片封装二维稳态热场代理模型**，用于展示：

- 有限元网格到图数据的转换与学习；
- 工程热仿真在多工况场景下的加速潜力；
- AI for Science（AI4S）在封装热分析中的落地路径。

项目**不依赖**任何企业内部代码、数据或模型；温度场标签全部由开源有限元库 scikit-fem 实际求解生成；报告中的全部数值指标均来自真实训练与测试运行，**未伪造**。

1.1 核心任务定义

给定二维芯片封装截面的材料参数、热源工况与边界条件，代理模型直接预测网格各节点的温升场

$$\Delta T(\mathbf{x}) = T(\mathbf{x}) - T_{\text{amb}},$$

并与有限元真值对比，评估精度、泛化与推理速度。

1.2 技术栈

Python、PyTorch、PyTorch Geometric、NumPy、SciPy、scikit-fem、Matplotlib、Pandas、PyYAML、pytest。

1.3 项目目录结构

```
chip-thermal-gnn/  
  README.md  
  requirements.txt  
  configs/ # 数据与训练配置  
  data/raw/ # FEM 原始样本  
  data/processed/ # PyG 图数据  
  outputs/  
    checkpoints/ # 最优权重  
    figures/ # 可视化图片  
    metrics/ # 指标表与评估摘要  
  src/ # 全部可执行脚本  
  tests/ # 单元测试  
  docs/ # 本 LaTeX / PDF 文档
```

2 物理模型与假设

2.1 几何结构

采用二维矩形封装截面（宽 20 mm，高 12 mm），自下而上四层：基板（Substrate）→ 铜散热层（Cu）→ 导热界面材料（TIM）→ Die（硅）。几何示意与规则三角形有限元网格见图 1。




Figure 1: 二维芯片封装截面结构与规则三角形有限元网格。顶部为对流边界，底部为恒温边界，左右绝热；红色虚线表示 Die 层中位置与宽度随机采样的热点区域。

各层厚度与导热系数采样范围见表 1。

Table 1: 封装层级、厚度与导热系数采样范围

层级	材料	厚度	k 范围 [W/(m · K)]
基板 Substrate	有机/陶瓷类	6 mm	15 ~ 60
散热层	铜	3 mm	360 ~ 400
界面材料 TIM	膏体/垫片类	1 mm	1 ~ 8 (OOD: 0.2 ~ 0.9)
Die	硅	2 mm	130 ~ 155

2.2 控制方程

稳态热传导：

$$-\nabla \cdot (k \nabla T) = q, \quad (1)$$

其中 $k(\mathbf{x})$ 为分材料导热系数， $q(\mathbf{x})$ 为体热源功率密度。

2.3 边界条件（简化设置）

- **顶部**（Die 上表面）：对流边界

$$-k \frac{\partial T}{\partial n} = h_{\text{top}} (T - T_{\text{amb}}), \quad h_{\text{top}} \in [500, 15000] \text{ W}/(\text{m}^2 \cdot \text{K})$$

(OOD 测试: $100 \sim 400$);

- **底部** (基板下表面): 恒温 Dirichlet 边界 $T = T_{\text{amb}}$;
- **左右两侧**: 绝热 (零通量自然边界条件)。

2.4 热源设置

Die 层内施加体热源: 背景功率密度 $q_{\text{base}} \in [10^5, 5 \times 10^5] \text{ W/m}^3$ 与矩形热点 $q_{\text{hot}} \in [5 \times 10^6, 3 \times 10^7] \text{ W/m}^3$ (OOD: $3.5 \times 10^7 \sim 6 \times 10^7$)。热点中心位置与宽度在芯片宽度比例范围内随机采样。

2.5 明确的物理简化假设

1. 二维截面近似 (单位深度);
2. 各层厚度相对真实封装等比放大, 便于规则网格质量与可视化;
3. 材料线性、各向同性, k 与温度无关;
4. 层间无额外接触热阻 (TIM 层显式代表界面热阻);
5. 边界简化: 底部理想恒温、侧面绝热、仅顶部对流;
6. 关于 T_{amb} : 因问题线性且边界均以 T_{amb} 为参考, 温升场 ΔT 在数学上与 T_{amb} 取值无关; 数据集中仍对其采样并保留特征, 以便未来扩展到温度相关材料属性 (非线性问题)。

3 数据生成与图构建

3.1 有限元离散

使用 scikit-fem 的 `MeshTri.init_tensor` 生成规则三角形网格: 61×37 节点, 共 2257 个节点、4320 个三角单元。所有样本共用同一张网格 (固定几何、变工况)。单元采用线性三角元 P_1 , 组装刚度矩阵与热源载荷, 顶部叠加 Robin (对流) 边界, 底部施加 Dirichlet 条件后求解。

实测平均单次 FEM 求解耗时约 8.50 ms (本机 RTX 3060 环境下的 SciPy 稀疏求解)。

3.2 数据集划分

共生成 360 个样本, 划分见表 2。测试集中包含至少一种训练集未出现的工况组合 (更高热源功率、更差 TIM 导热系数、更差对流条件), 用于验证外推泛化。

Table 2: 数据集划分

子集	样本数	工况分布	说明
训练集	300	分布内	参数在配置范围内均匀采样
验证集	30	分布内	早停与学习率调度
测试集	30	20 分布内 + 10 OOD	OOD 含高功率/差 TIM/差对流

每个样本保存: 节点坐标、材料类别、节点热源特征、边界特征、三角形连接关系、节点温度场标签、工况元数据。原始数据位于 `data/raw/`, 并写入包含采样范围、划分与随机种子的 `metadata.json` (种子 = 2024)。

3.3 图数据表示

每个 FEM 样本转换为一个 `torch_geometric.data.Data` 对象，字段如下：

- $\mathbf{x} \in \mathbb{R}^{N \times 21}$ ：节点特征。包含归一化坐标、材料 one-hot、局部热源强度、环境温度、边界换热系数与边界类型标志，以及**广播到全部节点的全局工况特征**（各层 k 、 $q_{\text{base}}/q_{\text{hot}}$ 、热点位置/宽度、TIM 与对流热阻）；
- `edge_index`：由三角单元生成的无向边（双向去重），共 13152 条有向边；
- `edge_attr` $\in \mathbb{R}^{E \times 4}$ ：归一化相对坐标 $(\Delta x, \Delta y)$ 、边长、两端点导热系数的调和平均；
- $\mathbf{y} \in \mathbb{R}^N$ ：节点温升 ΔT （优先预测温升而非绝对温度）；
- `pos`：节点物理坐标，用于可视化。

为何广播全局工况特征：稳态导热是椭圆型方程，任一点温度受全域参数影响。消息传递轮数有限（8 轮）而网格图直径约数十跳；若不广播，远离热源/边界的节点难以感知工况，模型精度会受结构性限制。这是稳态（非时间步进）图代理模型的常见做法。

4 模型设计

4.1 主模型：MeshGraphNet 风格 Encode–Process–Decode

1. **Node Encoder / Edge Encoder**：MLP 将节点/边特征映射到 128 维隐空间；
2. **Processor**：8 轮残差消息传递。每轮先由源节点、目标节点与边隐变量经 MLP 更新边隐变量（残差），再按目标节点求和聚合并经 MLP 更新节点隐变量（残差）；全部 MLP 带 LayerNorm 与 dropout；
3. **Decoder**：两层 MLP 输出单节点标准化温升。

主模型参数量约 979,329。

实现参考 DeepMind MeshGraphNets (ICLR 2021) 思想，代码从零编写；调研过的开源参考包括 DeepMind meshgraphnets (TensorFlow) 与 NVIDIA PhysicsNeMo 的 PyTorch/PyG MeshGraphNet 实现。公开预训练权重面向流体等其他场景，特征接口与本任务不兼容，故在自建 FEM 数据上从零训练。

4.2 基线模型

4 层 GraphSAGE（可配置为 GCNConv），不使用边特征，直接回归节点温升；参数量约 104,321。

4.3 损失函数与训练策略

- 主损失：在全局标准化温升空间中，采用**逐样本相对形式**（每样本误差能量除以该样本自身信号能量），避免高功率大温升样本主导损失；
- 辅助项：峰值温度误差（真实温升最大节点处的预测误差平方），权重 0.1；
- 优化器 Adam ($\text{lr} = 10^{-3}$)，ReduceLROnPlateau，梯度裁剪，早停耐心 40，固定随机种子 2024，保存验证集最优权重。

训练实测摘要见表 3。

Table 3: 训练摘要（本机实测）

模型	最佳 epoch	最佳验证损失	总训练轮数	训练时长
MeshGraphNet	296	0.01404	336	≈ 56 min
GraphSAGE 基线	265	0.00837	305	≈ 4 min

训练/验证损失曲线见图 2。




Figure 2: MeshGraphNet 与 GraphSAGE 基线的训练/验证损失曲线（对数纵轴）。虚线标出验证集最优 epoch。

5 评估指标与实验结果

评估在测试集 30 个样本上进行，硬件为 NVIDIA GeForce RTX 3060。指标定义：

- **节点温度 MAE**: $\frac{1}{N} \sum_i |\widehat{\Delta T}_i - \Delta T_i|$;
- **相对 L_2 误差**: $\|\widehat{\Delta T} - \Delta T\|_2 / \|\Delta T\|_2$;
- **峰值温度绝对误差**: $|\max \widehat{\Delta T} - \max \Delta T|$;
- R^2 : 全测试集节点温升的决定系数;
- **耗时**: 单样本推理、批量摊销推理与平均 FEM 求解时间。

5.1 整体对比

整体测试集结果见表 4，柱状对比见图 3。

Table 4: 测试集整体指标对比（实测）

模型	参数量	MAE [K]	相对 L_2	峰值误差 [K]	R^2	单样本推理 [ms]	批量摊销 [ms]
MeshGraphNet	979329	0.1095	0.2294	0.3562	0.9228	10.23	6.77
GraphSAGE	104321	0.1035	0.2231	0.3431	0.9270	2.08	0.46

Table 5: 相对 FEM 的加速比（平均 FEM ≈ 8.50 ms）

模型	单样本加速比	批量加速比	说明
MeshGraphNet	$0.83\times$	$1.25\times$	小网格下 FEM 本身很快
GraphSAGE	$4.09\times$	$18.5\times$	批量多工况扫描更有优势




Figure 3: 主模型与基线模型测试集指标柱状图对比。

解读:

- 在引入全局工况特征后，两模型整体精度接近， $R^2 > 0.92$;
- 本例网格仅约 2257 节点，稀疏直接法 FEM 本身极快，单样本 GNN 相对 FEM 的加速有限；**批量多工况**下 GraphSAGE 可达约 18 $\times$;
- 网格规模增大（如 10^5+ 节点）时，FEM 成本上升更快，代理模型加速比通常更显著。

5.2 分布内 / 分布外分拆

表 6 与表 7 给出分工况指标。

Table 6: MeshGraphNet: 分布内 / OOD 分拆

工况类型	样本数	MAE [K]	相对 L_2	峰值误差 [K]
分布内 (id)	20	0.0389	0.0736	0.0807
OOD 高功率	4	0.1867	0.1694	0.4634
OOD 差 TIM	3	0.2074	0.3844	0.9186
OOD 差对流	3	0.3798	0.4422	1.4873

Table 7: GraphSAGE 基线: 分布内 / OOD 分拆

工况类型	样本数	MAE [K]	相对 L_2	峰值误差 [K]
分布内 (id)	20	0.0308	0.0627	0.0829
OOD 高功率	4	0.1166	0.0860	0.1642
OOD 差 TIM	3	0.2156	0.3784	0.7643
OOD 差对流	3	0.4589	0.6504	1.8947

分布内 MAE 约 0.03 ~ 0.04 K，精度很高；OOD（尤其差对流）误差明显增大，说明外推仍有挑战，同时也证明测试集确实包含训练集未见工况组合。

5.3 峰值温度散点图

图 4 给出测试样本峰值温升真值-预测对比；红色三角为 OOD 样本。






Figure 4: 测试集峰值温升：真值 vs 预测。蓝色为分布内，红色三角为分布外。

6 温度场可视化


对自动挑选的代表性测试样本，绘制真实温升场、预测温升场与误差场三联图。图 5 与图 6 分别展示 MeshGraphNet 与基线结果（含分布内与 OOD 样本）。



(a) 样本 4



(b) 样本 18



(c) 样本 28 (含较高温升/OOD 倾向样本)

Figure 5: MeshGraphNet: 真实温度场、预测温度场与误差场三联图。




Figure 6: GraphSAGE 基线：真实温度场、预测温度场与误差场三联图。

从场图可见：分布内样本的热点位置与温升形态可被较好重建；误差主要集中在材料界面与热点边缘等高梯度区域；OOD 样本的峰值误差相对更大。

7 复现实验步骤

```

pip install -r requirements.txt

# 1. 生成 FEM 数据集 (约 360 次求解)
python src/generate_dataset.py --config configs/data_config.yaml --out_dir data/raw

# 2. 网格 -> 图数据
python src/graph_dataset.py --raw_dir data/raw --out_dir data/processed

# 3. 训练
python src/train.py --model meshgraphnet
python src/train.py --model baseline

# 4. 评估
python src/evaluate.py

# 5. 可视化
python src/visualize.py

```

```
# 6. 单元测试
python -m pytest tests -q

# 7. 编译本说明文档 (需 TeX Live / XeLaTeX)
cd docs
xelatex -interaction=nonstopmode report.tex
xelatex -interaction=nonstopmode report.tex
```

关键配置：

- configs/data_config.yaml: 几何、材料/工况采样范围、OOD 设置、数据划分;
- configs/train_config.yaml: 模型超参数、损失类型、早停与学习率策略。

8 局限性与后续扩展

8.1 当前局限性

1. 固定网格与固定几何，未验证跨网格/跨几何泛化;
2. 二维简化，未建模三维热扩散;
3. 线性稳态，无温度相关材料、辐射或接触热阻;
4. 样本量适中 (360)，更大规模数据可进一步提升 OOD 外推;
5. 小网格下相对 FEM 的单样本加速比有限。

8.2 从稳态扩展到瞬态

1. **数据端**: 增加热容项 $\rho c \partial T / \partial t$ ，用隐式时间积分生成温度序列;
2. **模型端**: 改为自回归时间步进 $T(t + \Delta t) = T(t) + \text{GNN}(T(t), \text{条件})$;
3. **训练技巧**: 输入噪声注入抑制 rollout drift，评估长时间稳定性;
4. **应用**: 支持时变功耗 $q(t)$ ，实现瞬态热响应预测。

9 结论

本项目完成了从 FEM 数据生成、图构建、MeshGraphNet / GraphSAGE 训练、测试评估到可视化的完整闭环。在分布内工况下，节点温升 MAE 可达约 $0.03 \sim 0.04 \text{ K}$ ，整体 $R^2 \approx 0.92 \sim 0.93$ ；在 OOD 工况下误差增大，尤其差对流条件更具挑战。在当前小规模网格上，代理模型的优势更体现在**批量多工况推理**；扩大网格规模后，相对 FEM 的加速潜力将进一步体现。该系统可作为芯片封装热分析与 AI4S 演示的可复现基线。

A 主要输出文件索引

- 权重: outputs/checkpoints/meshgraphnet_best.pt, outputs/checkpoints/baseline_best.pt
- 指标: outputs/metrics/model_comparison.csv, outputs/metrics/*_eval_summary.json
- 图片: outputs/figures/*.png
- 原始元数据: data/raw/metadata.json