

基于图神经网络的芯片封装二维/三维稳态热场代理模型

统一技术说明文档 (chip-thermal-gnn)

项目可复现基线报告：二维流程 + 三维四面体 FEM 扩展

2026 年 9 月 2 日

本报告以 docs/report.tex 的 XeLaTeX 排版体系为基础重建；所有标注为“实测”的数值均可追溯到 outputs/ 下的 JSON、CSV、图像或测试记录。

Contents

1	项目概述与结论摘要	3
1.1	任务定义	3
1.2	当前可复现结论	3
1.3	范围与非目标	3
2	物理模型与有限元理论	3
2.1	分层几何与材料	3
2.2	控制方程和边界条件	4
2.3	弱式与 P1 单元	5
2.4	热源参数化	5
3	数据集与 PyG 图构建	5
3.1	数据拆分与可重复性	5
3.2	节点与边特征	6
4	网络架构与训练方法	7
4.1	GraphSAGE 基线	7
4.2	MeshGraphNet 风格 Encode–Process–Decode	7
4.3	损失函数、优化和早停	8
5	验证与测试方案	9
5.1	分层测试原则	9
5.2	三维真实后端测试	9
5.3	制造解 (MMS) 收敛验证	9
5.4	学习代理的评估指标	10
6	二维流程的已有结果	10
6.1	训练摘要	10
7	三维流程、结果与云图	11
7.1	三维数据生成与资源规模	11
7.2	GraphSAGE 可信基线与紧凑 MGN 探针	11
7.3	三维切面云图	12
7.4	二维与三维的审慎对比	15
8	开源方案、外部参考与许可边界	15

9 复现实验与产物索引	16
10 需补充的代码与实验管线	17
11 图表补全与阅读路径	17
12 局限性与后续工作	18
13 结论	18

1 项目概述与结论摘要

1.1 任务定义

本项目构建从封装结构、材料、热源和边界条件到节点温升场的图神经网络代理模型。完整闭环为

参数化封装与工况 → P1 FEM 求解 → 网格转 PyG 图 → GNN 训练 → 场/峰值/OOD/成本评估 → 云图解释。

二维版本使用三角形 FEM 和 x 方向热点；三维版本保留二维文件与数据契约，新增真实四面体 FEM、Die 中的 $x-z$ 平面矩形热点和三维 PyG 图。温度标签均来自开源 scikit-fem 的实际数值求解，而非解析近似或虚构数据 [1]。

1.2 当前可复现结论

- 三维 GraphSAGE 是当前可信主基线：测试集 MAE **0.0835 K**、峰值温升误差 **0.1206 K**、加权 OOD MAE **0.1866 K**；三维紧凑 MeshGraphNet 暂未超过它。
- 三维四面体实现已经过真实 scikit-fem 测试和制造解（MMS）网格收敛验证：**6 passed**，观测收敛阶为 1.677 与 1.830。
- 差对流 `ood_poor_cooling` 是最明显的外推短板；三维 GraphSAGE 的该组 MAE 为 0.5283 K，应优先改善边界表示和训练覆盖，而非盲目增加消息传递深度。
- 二维与三维均使用 300/30/30 的固定种子数据划分；三维具有更丰富的横向扩散信息，但四面体图的边数与 FEM 成本显著增加。

1.3 范围与非目标

本报告的目标是建立可复现的研究基线，而不是签核级热仿真。当前不包含温度相关材料参数、辐射、显式接触热阻、各向异性、封装翘曲、几何公差、瞬态热容或实验测温校准。所有“优于”结论仅在所述数据、网格、硬件和超参数下成立。

2 物理模型与有限元理论

2.1 分层几何与材料

二维结构为 $20\text{ mm} \times 12\text{ mm}$ 的封装截面；三维结构在此基础上增加 16 mm 深度。两者均由下而上包含 Substrate、Cu、TIM 与 Die 四层。




Figure 1: 二维封装截面、分层材料、三角形网格与热点示意。三维版本沿 z 方向扩展为体域，并把热点定义为 x - z 平面矩形。

Table 1: 层级、厚度与材料采样范围

层级	材料示意	厚度	导热系数 k [W/(m·K)]
Substrate	有机/陶瓷类	6 mm	15 ~ 60
Cu	铜散热层	3 mm	360 ~ 400
TIM	导热界面材料	1 mm	1 ~ 8 (OOD: 0.2 ~ 0.9)
Die	硅芯片	2 mm	130 ~ 155

2.2 控制方程和边界条件

在 $d \in \{2, 3\}$ 维域 Ω 内，求解稳态热传导方程

$$-\nabla \cdot (k(\mathbf{x}) \nabla T(\mathbf{x})) = q(\mathbf{x}), \quad \mathbf{x} \in \Omega, \quad (1)$$

其中 k 是分材料导热系数， q 是体热源密度。边界条件为

$$T = T_{amb}, \quad \text{on } \Gamma_{bottom}, \quad (2)$$

$$-k \nabla T \cdot \mathbf{n} = h_{top}(T - T_{amb}), \quad \text{on } \Gamma_{top}, \quad (3)$$

$$-k \nabla T \cdot \mathbf{n} = 0, \quad \text{on } \Gamma_{side}. \quad (4)$$

这里底部为理想散热地，顶部为 Robin 对流，二维侧边或三维剩余侧面为绝热。由于当前模型线性且所有边界均以 T_{amb} 为参考，学习目标采用

$$\Delta T(\mathbf{x}) = T(\mathbf{x}) - T_{amb}. \quad (5)$$

改变 T_{amb} 仅平移绝对温度而不改变 ΔT ；该变量仍作为已知条件保留，以适配未来温度相关物性的非线性扩展。

2.3 弱式与 P1 单元

令 $V_0 = \{v \in H^1(\Omega) : v|_{\Gamma_{bottom}} = 0\}$ 。弱式为：求满足 Dirichlet 条件的 T ，使任意 $v \in V_0$ 满足

$$\int_{\Omega} k \nabla T \cdot \nabla v \, d\Omega + \int_{\Gamma_{top}} h_{top} T v \, d\Gamma = \int_{\Omega} q v \, d\Omega + \int_{\Gamma_{top}} h_{top} T_{amb} v \, d\Gamma. \quad (6)$$

二维采用 3 节点线性三角元，三维采用 4 节点线性四面体。单元近似与局部装配为

$$T_h|_e = \sum_{i=1}^{n_e} N_i T_i, \quad K_{ij}^{(e)} = \int_{\Omega_e} k \nabla N_i \cdot \nabla N_j \, d\Omega, \quad f_i^{(e)} = \int_{\Omega_e} q N_i \, d\Omega, \quad (7)$$

其中 $n_e = 3$ (二维) 或 4 (三维)。三维顶面三角形 s 的 Robin 局部矩阵为

$$K_R^{(s)} = \frac{h_{top} A_s}{12} \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}, \quad (8)$$

右端增加 $h_{top} T_{amb} A_s / 3$ 。实现直接使用 scikit-fem 的稀疏形式组装、约束消元和求解 [1]。

2.4 热源参数化

二维 Die 内热点由中心 x_c 与宽度 w_x 定义。三维 Die 内热点是 x - z 矩形，沿 Die 厚度方向 y 延展：

$$q(x, y, z) = \begin{cases} q_{hot}, & y > y_{TIM}, x \in [x_c - w_x/2, x_c + w_x/2], z \in [z_c - w_z/2, z_c + w_z/2], \\ q_{base}, & y > y_{TIM} \text{ 且不在热点内}, \\ 0, & \text{其他层}. \end{cases} \quad (9)$$

Table 2: 工况采样与分布外测试范围

量	分布内范围	OOD 范围 (仅测试集部分样本)
q_{base} [W/m ³]	$1 \times 10^5 \sim 5 \times 10^5$	—
q_{hot} [W/m ³]	$5 \times 10^6 \sim 3 \times 10^7$	$3.5 \times 10^7 \sim 6 \times 10^7$
h_{top} [W/(m ² ·K)]	500 ~ 15000	100 ~ 400
T_{amb} [°C]	20 ~ 45	同分布内

3 数据集与 PyG 图构建

3.1 数据拆分与可重复性

二维和完整三维数据集均使用随机种子 2024，训练/验证/测试划分均为 300/30/30。测试集由 20 个分布内样本与 10 个 OOD 样本组成，覆盖高功率、低 TIM 导热和弱对流工况。所有样本保存工况元数据和 FEM 求解时间；温升均值/标准差仅从训练拆分统计，避免测试标签泄漏。

Table 3: 二维与三维 FEM-图数据规格

属性	二维流程	三维流程
有限元单元	P1 三角形	P1 四面体
规则网格	61×37	$13 \times 13 \times 11$
节点数	2,257	1,859
单元数	4,320 三角形	8,640 四面体
有向边数	13,152	22,532
节点特征维度	21	24
边特征维度	4	5
标签	节点温升 ΔT	节点温升 ΔT

三维节点数略少于二维，但四面体的 6 条顶点对导致边数增加约 71%。处理时对每个三角形或四面体的无向顶点对去重，再保留两个方向写入 `edge_index`；图中不含自环。

3.2 节点与边特征

节点特征由可观测局部量和广播到所有节点的全局工况量构成：归一化坐标、4 类材料 one-hot、局部热源、环境温度、局部对流系数、顶/底边界标志、热点几何、材料导热率与热阻式变量 $1/k_{TIM}$ 、 $1/h_{top}$ 。二维坐标为 $(x/W, y/H)$ ，三维额外加入 z/D ；因此三维热点全局量额外包含 z_c, w_z 。

边特征为归一化相对位移、边长和端点材料导热率调和平均

$$k_{ij} = \frac{2k_i k_j}{k_i + k_j}. \quad (10)$$


三维边特征新增 $\Delta z/D$ 。全局工况广播不是温度标签泄漏：它只提供部署时同样可知的设计参数。这样做的原因是稳态导热为全局耦合的椭圆型问题，有限消息传递步数不足以可靠地把远端热源或边界信息传过整个图。

处理后的样本使用 `torch_geometric.data.Data` 保存，含 `x`、`edge_index`、`edge_attr`、`y` 与 `pos`。PyTorch Geometric 为不规则图、图批处理与相关图卷积提供支持 [3]。

4 网络架构与训练方法

三维热场代理原型：离线 FEM 监督与在线 GNN 推理

GraphSAGE 为当前主基线；MGN 仅作为使用边属性的受控对照。



4.1 GraphSAGE 基线

GraphSAGE 是归纳图学习方法 [4]。其均值聚合的简化表达为

$$\mathbf{h}_v^{(\ell+1)} = \sigma \left(W^{(\ell)} \left[\mathbf{h}_v^{(\ell)} \parallel \text{mean}_{u \in \mathcal{N}(v)} \mathbf{h}_u^{(\ell)} \right] \right). \quad (11)$$

本项目的 GraphSAGE 直接回归节点标准化温升，不消费 edge_attr。它是必要的低复杂度基线，用于判断复杂边消息网络是否真正带来收益。

4.2 MeshGraphNet 风格 Encode–Process–Decode

MeshGraphNets 将网格表示为节点和边图，以编码、残差消息传递和解码器学习仿真映射 [5]。本项目仅借鉴其架构思想，模型在本地独立实现、从零训练，未复用任何外部权重或源码。第 ℓ 步消息

传递可写为

$$\mathbf{e}_{ij}^{(\ell+1)} = \mathbf{e}_{ij}^{(\ell)} + \phi_e([\mathbf{h}_i^{(\ell)}, \mathbf{h}_j^{(\ell)}, \mathbf{e}_{ij}^{(\ell)}]), \quad (12)$$

$$\mathbf{m}_i^{(\ell+1)} = \sum_{j:(j,i) \in E} \mathbf{e}_{ji}^{(\ell+1)}, \quad (13)$$

$$\mathbf{h}_i^{(\ell+1)} = \mathbf{h}_i^{(\ell)} + \phi_v([\mathbf{h}_i^{(\ell)}, \mathbf{m}_i^{(\ell+1)}]), \quad (14)$$

$$\widehat{\Delta T}_i = \psi(\mathbf{h}_i^{(L)}). \quad (15)$$

节点/边 MLP 使用 LayerNorm、dropout 与残差连接。MGN 消费边的几何与等效导热特征，因此在三维大边数图中会显著提高状态与聚合成本。

Table 4: 模型与训练配置

配置	2D GraphSAGE	2D MGN	3D GraphSAGE	3D 紧凑 MGN
层/消息步	4 层	8 步	3 层	2 步
隐藏维度	128	128	64	64
参数量	104,321	979,329	19,713	73,153
batch size	8	8	4	8
训练轮上限	500	500	120	12
CPU 线程约束	历史配置	历史配置	4	4

三维 MGN 特意先采用 2–4 步、64 或 96 维的紧凑搜索方向，而没有直接照搬二维的 8 步、128 维。原因是 3D 图的每条有向边都有边隐状态和 MLP 计算，过大的初始配置会使成本迅速膨胀。

4.3 损失函数、优化和早停

令 z 为使用训练拆分均值/标准差标准化后的温升。主损失采用逐样本相对能量形式：

$$\mathcal{L}_{field} = \frac{1}{B} \sum_{b=1}^B \frac{\sum_{i \in b} (\hat{z}_i - z_i)^2}{\sum_{i \in b} (z_i - \bar{z}_b)^2 + 10^{-4}}. \quad (16)$$

真实峰值节点 $i_b^* = \arg \max_{i \in b} z_i$ 处的辅助损失为

$$\mathcal{L} = \mathcal{L}_{field} + 0.1 \cdot \frac{1}{B} \sum_b (\hat{z}_{i_b^*} - z_{i_b^*})^2. \quad (17)$$

该设计避免高温升样本支配训练，并强化工程上关心的热点峰值。优化器为 Adam（初始学习率 10^{-3} ）、ReduceLROnPlateau、梯度裁剪 1.0、固定种子 2024 和验证集早停。




Figure 3: 二维历史训练的 MeshGraphNet 与 GraphSAGE 训练/验证损失曲线。该图用于展示二维流程收敛，不与三维紧凑 MGN 的训练轮数混比。

5 验证与测试方案

5.1 分层测试原则

测试被分为物理一致性、数据契约、网络可训练性和数值收敛四层。物理直觉测试可发现热源、边界和分层实现错误；数据契约测试可发现网格转图错误；网络前后向测试验证可训练性；MMS 独立验证离散随网格加密的数值行为。

Table 5: 二维与三维测试覆盖及证据状态

层级	测试内容	证据状态
2D FEM	温度有限、底部恒温、最高温在 Die、热源增大时峰值增大、材料层编号	tests/test_fem_solver.py 已定义；本次统一报告未重新运行
2D 图数据	三角形转双向去重边、无自环、21/4 维特征、处理文件形状	tests/test_graph_dataset.py 已定义；本次未重新运行
2D 网络	MGN 前向/反向梯度、GraphSAGE 与 GCN 前向形状	tests/test_models.py 已定义；本次未重新运行
3D FEM/图	四面体连通、边界、 $x-z$ 热点、双向边、24/5 维特征	已实际运行并通过
3D MMS	网格加密误差单调下降、收敛阶阈值	已实际运行并通过

二维测试代码和二维训练评估产物都保留在仓库中，但没有同一日期的二维 pytest 终端日志，因此本报告不将其误写为“本轮通过”。如需重新确认，命令为 `python -m pytest tests -q`；根据项目约定，应在运行前取得授权。

5.2 三维真实后端测试

实际执行的命令为

```
.\.venv-3d\Scripts\python.exe -m pytest \
  tests/test_fem_solver_3d.py tests/test_graph_dataset_3d.py \
  tests/test_mms_3d.py -q
```

结果为 6 passed，另有两条 PyTorch torch.jit.script 弃用警告，不影响 FEM 或图数据计算。

5.3 制造解 (MMS) 收敛验证

仅依靠“温度升高”“热点在 Die”不足以验证四面体离散。为此，在单位立方体选择解析解

$$T^*(x, y, z) = \sin(\pi x) \sin(\pi y) \sin(\pi z), \quad q = 3\pi^2 T^*, \quad (18)$$

并在全部边界施加与解析解一致的零 Dirichlet 条件。MMS 的验证理念参考 MOOSE 热传导验证教程 [6]，但本仓库的网格、装配、求解和测试均独立执行。

Table 6: 3D P1 四面体 MMS 网格收敛实测结果

每轴节点数	节点数	四面体数	节点 RMSE	最大绝对误差
5	125	384	2.4351×10^{-2}	9.5072×10^{-2}
9	729	3,072	7.6178×10^{-3}	2.5201×10^{-2}
13	2,197	10,368	3.6276×10^{-3}	1.1324×10^{-2}

相邻网格观测收敛阶为 1.677 与 1.830，误差随加密单调下降。这证明 P1 四面体实现对光滑解析解具有预期的收敛趋势，但不等同于真实封装实验验证。

5.4 学习代理的评估指标

对测试节点或每个样本的温升真值 ΔT 与预测 $\widehat{\Delta T}$ ，报告

$$\text{MAE} = \frac{1}{N} \sum_i |\widehat{\Delta T}_i - \Delta T_i|, \quad (19)$$

$$\text{RelL2} = \frac{\|\widehat{\Delta T} - \Delta T\|_2}{\|\Delta T\|_2}, \quad (20)$$

$$E_{\text{peak}} = |\max_i \widehat{\Delta T}_i - \max_i \Delta T_i|, \quad (21)$$

以及 R^2 、分工况 OOD MAE、单样本/批处理推理时间、FEM 时间与进程 RSS。不同硬件、线程数、batch 和模型大小的速度不得直接混合比较。

6 二维流程的已有结果

6.1 训练摘要

二维产物位于 outputs/metrics/。GraphSAGE 最佳验证 epoch 为 265，共训练 305 epoch，训练时间 231.57 s；MGN 最佳 epoch 为 296，共训练 336 epoch，训练时间 3,394.16 s。二维 GraphSAGE 当前保存评估的精度为

Table 7: 二维 GraphSAGE 当前保存评估摘要 (CPU 记录)

指标	数值
参数量	104,321
整体 MAE	0.1035 K
相对 L_2	0.2231
R^2	0.9270
平均峰值温升绝对误差	0.3431 K
ID / 高功率 / 差 TIM / 差对流 MAE	0.0308 / 0.1166 / 0.2156 / 0.4589 K
平均 FEM 时间	8.50 ms
单样本 / 批处理推理	54.94 / 56.01 ms/样本
评估进程 RSS	520.09 MiB

仓库旧版二维 PDF 中的 MGN 推理时间来自 RTX 3060 历史运行，不能与表 7 的 CPU 记录或三维 CPU 记录直接比较。二维结果表明在小网格上 FEM 本身很快，代理模型的价值主要体现在批量工况扫描、反复优化或更大规模网格场景。




Figure 4: 二维 GraphSAGE 代表样本：FEM 温升、预测温升与误差场三联图。




Figure 5: 二维测试集峰值温升真值-预测散点图；图中 OOD 样本用于观察外推误差。

7 三维流程、结果与云图

7.1 三维数据生成与资源规模

三维完整数据集保存在 data/raw_3d_full/ 与 data/processed_3d_full/。300/30/30 个样本的原始 FEM 生成耗时 39.41 s；全部样本平均单次 FEM 求解时间为 92.61 ms，测试评估平均为 112.25 ms。小规模烟雾数据集的温升范围为 0.2987–2.1923 K，单图张量约 0.972 MiB；完整处理集的训练图文件约 189.4 MiB。

7.2 GraphSAGE 可信基线与紧凑 MGN 探针

Table 8: 三维模型实测结果 (CPU)

模型	最佳/总 epoch	参数量	训练时间 [s]	MAE [K]	RelL2	R^2	峰值误差 [K]	OOD MAE [K]
GraphSAGE	69 / 94	19,713	439.29	0.0835	0.4945	0.6509	0.1206	0.1866
紧凑 MGN	11 / 12	73,153	343.80	0.1433	0.7079	0.2846	0.1529	0.3060

Table 9: 三维计算成本与 OOD 分拆

指标	3D GraphSAGE	3D 紧凑 MGN
训练 RSS 峰值	597.64 MiB	887.57 MiB
评估 RSS	600.84 MiB	1,434.16 MiB
单样本 / 批处理推理	7.43 / 6.43 ms	19.13 / 20.98 ms
平均 FEM 时间	112.25 ms	112.25 ms
ID MAE	0.0319 K	0.0620 K
高功率 OOD MAE	0.0489 K	0.1875 K
差 TIM OOD MAE	0.0283 K	0.0652 K
差对流 OOD MAE	0.5283 K	0.7048 K

在当前相同数据划分下，GraphSAGE 在精度、OOD、推理时间和内存上都优于紧凑 MGN。因此 GraphSAGE 是冻结的三维主基线；MGN 的 12 epoch 结果只说明小配置尚未学习充分，不能据此推断其理论上无效。




Figure 6: 三维模型选型图。对整体 MAE、按 OOD 样本数加权的 OOD MAE、单样本推理时间和评估 RSS 四项用于当前决策的指标，GraphSAGE 均优于本轮紧凑 MGN；因此主推 GraphSAGE 是实测选择，而非架构偏好。




Figure 7: ID 与 OOD 分项误差。差对流是两个模型共同的最大难例；高功率下 MGN 的峰值误差略小，但其场 MAE、其他 OOD 组别和总体成本均不占优。图用于定位后续物理覆盖，而非把单一平均数当作充分结论。

7.3 三维切面云图

每张三维图按列展示 FEM、GNN 预测和预测减 FEM 的误差；按行展示 Die 中心 $x-z$ 热点平面、中心 $y-z$ 平面和中心 $x-y$ 平面。




Figure 8: 三维 GraphSAGE: 中位 ID 样本 #19。FEM 峰值 0.708 K, 预测峰值 0.783 K。热点位置和厚度方向热扩散得到重建, 误差主要集中在热点周围和材料界面。

3D slice clouds | baseline | sample 27 | ood_poor_cooling | FEM peak=2.722 K, prediction peak=3.437 K




Figure 9: 三维 GraphSAGE: 差对流 OOD 样本 #27。FEM 峰值 2.722 K，预测峰值 3.437 K。模型在三个切面均有大范围整体高估，直观对应 0.5283 K 的该工况 MAE。

3D GraphSAGE: 同一 x - z 热点切面上的 ID 与 OOD 对照

ID 成功: 样本 #19, 热点位置与厚度方向扩散均被捕捉

差对流 OOD 失败: 样本 #27, 整体温升被系统性高估




Figure 10: ID 成功与差对流 OOD 失败的直接对照，仅展示同一 x - z 热点切面以保证可读性。左侧热点空间位置和厚度方向扩散基本一致；右侧预测温升在面内被整体高估。完整三切面云图见图 8 和图 9。

7.4 二维与三维的审慎对比

Table 10: GraphSAGE 的二维与三维对比

指标	2D	3D
节点 / 有向边	2,257 / 13,152	1,859 / 22,532
参数量	104,321	19,713
MAE	0.1035 K	0.0835 K
峰值误差	0.3431 K	0.1206 K
加权 OOD MAE	0.2490 K	0.1866 K
平均 FEM 时间	8.50 ms	112.25 ms
评估 RSS	520.09 MiB	600.84 MiB

三维在当前数据上具有更低的场、峰值和 OOD 误差，但这不能简单解释为“维数提升必然更好”：二维和三维的网络宽度、层数、物理难度和速度记录不同。稳健结论是：三维提供了真实横向扩散表征，代价是更多边和明显更高的 FEM 数据生成成本。

8 开源方案、外部参考与许可边界

Table 11: 本项目采用或审查的开源方案

资源	在本项目中的作用	使用边界
scikit-fem [1]	实际三角形/四面体 FEM 组装和稀疏求解	直接依赖；FEM 标签由实际求解得到
PyTorch 与 PyG [2, 3] GraphSAGE [4]	张量训练、图数据对象和图卷积归纳图神经网络基线理论	直接依赖；所有权重从零训练 本项目本地构建模型，不使用外部权重
MeshGraphNets [5]	Encode–Process–Decode 架构参考	本地独立实现；其公开流体/结构权重不用于热任务
MOOSE [6]	MMS 与网格收敛验证方法参考	仅方法参考；本项目独立执行 MMS
MFIT [7]	2.5D/3D 多芯粒 RC/DSS 与输入案例参考	已下载；GPL-3.0，未合并源码； 其 Windows 不支持 Linux .so， 故未运行数值对比
Multi-topology Dataset [8]	功率模块温度/功率/材料掩膜参考	CC BY 4.0；已读取一个 HDF5 样本； 二维顶表面绝对温度不与本项目三维节点温升直接算 MAE

Multi-topology 的已运行公开样本为 Mask_HB_V3-0/141_Pigbt450_Pfwd200_h6000，包含 256×256 顶表面温度、功率、芯片实例和铜/陶瓷/底板掩膜。温度范围为 $46.3787\text{--}155.626\text{ }^{\circ}\text{C}$ ，6 个芯片峰值为 $145.440\text{--}155.626\text{ }^{\circ}\text{C}$ ， $h = 6000$ 。这是一项外部数据格式与可视化参考，不构成同几何精度竞赛。




Figure 11: Multi-topology 公共样本：温度场、功率图、芯片实例图和材料掩膜。它说明可获得的跨拓扑输入输出格式，但不是本项目三维四面体标签。

若与 MFIT 或其他外部求解器开展数值比较，必须统一几何、材料、功率单位、底部边界、顶面对流、绝对温度/温升定义、网格收敛准则和误差掩膜；在此之前只能进行定性或数据格式对比。

9 复现实验与产物索引

独立环境安装采用系统信任库，禁止通过关闭证书验证绕过 TLS：

```
python -m venv .venv-3d
.\venv-3d\Scripts\python.exe -m pip install --use-feature=truststore -r requirements.txt
```

二维数据、训练和评估：

```
python src/generate_dataset.py --config configs/data_config.yaml --out_dir data/raw
python src/graph_dataset.py --raw_dir data/raw --out_dir data/processed
python src/train.py --model baseline --data_dir data/processed --config configs/train_config.yaml --out_dir outputs
python src/evaluate.py --data_dir data/processed --ckpt_dir outputs/checkpoints --out_dir outputs
python src/visualize.py
```

三维测试、数据、训练和云图：

```
.\venv-3d\Scripts\python.exe -m pytest tests/test_fem_solver_3d.py tests/test_graph_dataset_3d.py tests/test_mms_3d.py -q
.\venv-3d\Scripts\python.exe src/generate_dataset_3d.py --config configs/data_config_3d_full.yaml --out_dir data/raw_3d_full
.\venv-3d\Scripts\python.exe src/graph_dataset_3d.py --raw_dir data/raw_3d_full --out_dir data/processed_3d_full
.\venv-3d\Scripts\python.exe src/train.py --model baseline --data_dir data/processed_3d_full --config configs/train_config_3d.yaml --out_dir outputs/3d
.\venv-3d\Scripts\python.exe src/evaluate.py --data_dir data/processed_3d_full --ckpt_dir outputs/3d/checkpoints --out_dir outputs/3d --cpu_threads 4
.\venv-3d\Scripts\python.exe src/visualize_3d.py --model baseline
```

关键产物包括:outputs/metrics/*_eval_summary.json、outputs/3d/metrics/*_eval_summary.json、outputs/3d/metrics/mms_3d_convergence.json、outputs/figures/ 和 outputs/3d/figures/。任何改变网格、随机种子、硬件、线程、拆分或超参数的运行应写入新的输出目录，避免覆盖本基线。

10 需补充的代码与实验管线

本节列出的是**研究验证待办**，服务于证明或证伪具体假设；不是面向客户部署、批量交付或 SLA 的工程管线。工作量按一名熟悉本项目的研究者估计，不含等待计算资源的排队时间。所有新实验应保留配置、随机种子、版本与原始 JSON/CSV，且不得覆盖本报告的冻结基线。

Table 12: 优先补充的代码与实验管线

优先级	目的 (证明什么能力)	具体做什么	预期产出	工作量
P0	定位最坏 OOD，而非只报平均数	按场 MAE/峰值排序；按四种工况导出最坏 k 个样本和云图	failure_cases.csv、图册、归因	0.5–1 人日
P0	全流程可在容差内重现	固定 seed=2024 串联生成、建图、训练、评估；记录版本、线程与文件哈希	一条命令、reproducibility_manifest.json 日核对表	0.5–1 人日
P1	量化特征、峰值损失与深度的必要性	全局特征置零；peak_loss_weight=0；层数 2/3/4；保持同一划分	ablation.csv、柱状图、结论	1–2 人日
P1	分清 FEM、建图与前向的瓶颈	对求解、NPZ、建图、加载、前向分段计时；扫描节点/边与 batch，记录 RSS	complexity_profile.csv/json、堆叠/标度图	1 人日
P2	保证报告数字自动可追溯	从评估 JSON/CSV 生成含配置指纹、ID/OOD、峰值、时间和 RSS 的结果卡	results_card.md/png、生成脚本	0.5 人日
P2	判断外部案例是否可比	统一单位、几何、材料、边界、温度基准与误差掩膜；同条件后才运行	对齐协议、检查表、对比 CSV	1–2 人日

11 图表补全与阅读路径

本节新增的图 2、6、7 与 10 由 src/generate_technical_report_figures.py 从冻结的结果摘要和既有云图产生，不会触发 FEM 或训练；原始三切面云图和外部参考图仍由各自的可视化流程生成。它们的作用与状态如下：

- **端到端原型/方法流程图 (图 2, 已完成)**: 交代离线四面体 FEM 监督、三维 PyG 图、GraphSAGE 主基线、MGN 边属性边界与逐节点温升输出，避免把规划能力写成当前已实现能力。
- **ID vs OOD 对比云图 (图 10, 已完成)**: 把成功的 ID 样本与差对流失败样本放在同一视野；完整三切面留在图 8–9 以支持空间判读。
- **OOD 分项误差图 (图 7, 已完成)**: 显示差对流是最大短板，并避免只报告平均 OOD MAE。
- **模型对比/选型图 (图 6, 已完成)**: 用同一数据划分的误差、速度和 RSS 说明为何当前主推 GraphSAGE；该结论不外推到尚未充分训练或参数预算不同的 MGN。
- **消融结果图 (待 P1 消融完成)**: 统一展示去全局特征、去峰值损失和 2/3/4 层深度的场/峰值/OOD 误差；在没有对应运行记录前不填入假设性柱状数值。

12 局限性与后续工作

1. **物理保真度**: 需增加接触热阻、各向异性、温度相关材料、真实层厚、辐射和实验或高保真 FEM 校准。
2. **网格/几何泛化**: 当前每个维度中的样本共享网格; 后续应随机化层厚、热点形状和网格密度, 并采用跨网格测试。
3. **OOD**: 优先增加低 h_{top} 样本、显式编码散热路径, 并报告最坏样本/置信区间, 而非只报告平均 MAE。
4. **MGN 优化**: 仅当在相同数据拆分、参数预算和指标下超过 3D GraphSAGE, 才逐步增加消息传递步数或隐藏维度。
5. **外部基准**: 先在 Linux/WSL 确认 MFIT 及 SuperLU 可复现, 再进行同条件 RC-FEM-GNN 比较; 外部二维数据可用于迁移或跨拓扑研究, 不能替代三维体场验证。

13 结论

本项目已形成保留二维流程的三维热场代理基线: 真实 P1 四面体 FEM、三维 PyG 图、真实后端测试、MMS 收敛、GraphSAGE 基线、紧凑 MGN 对照和三维云图均已具备。当前最可靠的下一步不是立刻扩大 MGN, 而是围绕差对流 OOD 进行物理覆盖和边界特征改进, 并在统一条件下引入外部高保真参考。

References

- [1] T. Gustafsson and G. D. McBain, “scikit-fem: A Python package for finite element assembly,” *Journal of Open Source Software*, 5(52), 2369, 2020. <https://doi.org/10.21105/joss.02369>
- [2] A. Paszke et al., “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” *NeurIPS*, 2019. <https://pytorch.org/>
- [3] M. Fey and J. E. Lenssen, “Fast Graph Representation Learning with PyTorch Geometric,” 2019. <https://arxiv.org/abs/1903.02428>
- [4] W. L. Hamilton, R. Ying and J. Leskovec, “Inductive Representation Learning on Large Graphs,” *NeurIPS*, 2017. <https://proceedings.neurips.cc/paper/2017/hash/5dd9db5e033da9c6fb5ba83c7a7e9bea9-Abstract.html>
- [5] T. Pfaff, M. Fortunato, A. Sanchez-Gonzalez and P. Battaglia, “Learning Mesh-Based Simulation with Graph Networks,” *ICLR*, 2021. https://openreview.net/pdf?id=roNqYL0_XP
- [6] MOOSE Framework, “Heat Conduction Verification Tutorial.” https://mooseframework.inl.gov/releases/moose/2022-06-10/getting_started/examples_and_tutorials/tutorial03_verification/index.html
- [7] A. Kanani et al., “MFIT: Multi-Fidelity Thermal Modeling for 2.5D and 3D Multi-Chiplet Architectures.” <https://github.com/AlishKanani/MFIT>
- [8] R. Ke, J. Tao and C. Liu, “Multi-topology Power Module Thermal Simulation Dataset.” <https://github.com/henkuailederen/Multi-topology-Dataset>